

PRAKTIKUM 2
II4012 – INTELIGENSI ARTIFISIAL UNTUK BISNIS
Teknik Penambangan Data – Regresi



Disusun oleh:

Ahmad Evander Ruizhi Xavier	18223064
Sebastian Albern Nugroho	18223074

PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
2025

DAFTAR ISI

DAFTAR ISI.....	1
DAFTAR GAMBAR.....	2
DAFTAR TABEL.....	3
BAB I	
PEMAHAMAN DATA.....	4
1.1 Dataset Description.....	4
1.2 Check for Missing Values and Duplicates.....	5
1.3 Descriptive Statistics.....	6
1.4 Data Distribution Analysis.....	7
1.5 Identify Outliers.....	8
1.6 Trend Analysis and Visualization.....	10
1.7 Categorical Variable Analysis.....	11
1.8 Feature Selection and Justification.....	12
BAB II	
TAHAPAN PREPROCESSING.....	14
2.1 One-hot Encoding.....	14
2.2 Separate Independent and Dependent Variable.....	14
2.3 Feature Scaling.....	15
BAB III	
EVALUASI MODEL.....	16
3.1 Regresi Linear (Linear Regression).....	16
3.2 Regresi Linear Berganda (Multiple Linear Regression).....	17
3.3 Regresi Polinomial (Polynomial Linear Regression).....	18
3.4 Perbandingan Antar Model.....	18
BAB IV	
ANALISIS PENGARUH FITUR TERHADAP PREDIKSI.....	19
4.1 ???.....	19
BAB V	
INTERPRETASI HASIL UNTUK PENGAMBILAN KEPUTUSAN BISNIS.....	20

DAFTAR GAMBAR

Gambar 1.1: Cuplikan lima baris pertama (head) dataset training yang digunakan.....	4
Gambar 1.2: Informasi baris, kolom, dan tipe data variabel dataset training yang digunakan.....	4
Gambar 1.3: Jumlah missing values setiap kolom dataset training.....	6
Gambar 1.4: Jumlah data duplikat pada dataset training.....	6
Gambar 1.5: Statistik deskriptif pada dataset training.....	7
Gambar 1.6: Histogram distribusi data numerik pada dataset training.....	8
Gambar 1.7: Box plot variabel Square Footage pada dataset training.....	9
Gambar 1.8: Box plot variabel Energy Consumption pada dataset training.....	9
Gambar 1.9: Analisis korelasi fitur numerik pada dataset training.....	10
Gambar 1.10: Scatter plot Square Footage dengan Energy Consumption pada dataset training.....	11
Gambar 1.11: Frekuensi setiap kategori pada variabel Building Type.....	12
Gambar 1.12: Frekuensi setiap kategori pada variabel Day of Week.....	12
Gambar 2.1: One-hot encoding pada variabel kategorikal.....	14
Gambar 3.1: Perbandingan nilai aktual vs nilai prediksi pada model regresi linear.....	17
Gambar 3.2: Hasil perhitungan MAE, MSE, dan R^2 pada model regresi linear.....	17

DAFTAR TABEL

Tabel 3.1: Sub-pertanyaan dari test case yang ditentukan.....	19
---	----

BAB I

PEMAHAMAN DATA

1.1 Dataset Description

Dataset yang digunakan dalam praktikum ini berfokus pada analisis konsumsi energi pada berbagai jenis bangunan. Data mencakup beberapa faktor yang dapat mempengaruhi penggunaan energi, seperti luas bangunan, jumlah penghuni, penggunaan peralatan, serta suhu rata-rata. Selain itu, terdapat juga informasi seperti jenis bangunan dan hari operasional yang dapat memberikan pengaruh tambahan terhadap pola konsumsi energi. Berikut adalah cuplikan dan informasi dari dataset *training* yang digunakan:

	Building Type	Square Footage	Number of Occupants	Appliances Used	Average Temperature	Day of Week	Energy Consumption
0	Residential	7063	76	10	29.84	Weekday	2713.95
1	Commercial	44372	66	45	16.72	Weekday	5744.99
2	Industrial	19255	37	17	14.30	Weekend	4101.24
3	Residential	13265	14	41	32.82	Weekday	3009.14
4	Commercial	13375	26	18	11.92	Weekday	3279.17

Gambar 1.1: Cuplikan lima baris pertama (*head*) dataset *training* yang digunakan

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 7 columns):
 #   Column                      Non-Null Count  Dtype
---  -
 0   Building Type               1000 non-null   object
 1   Square Footage              1000 non-null   int64
 2   Number of Occupants         1000 non-null   int64
 3   Appliances Used              1000 non-null   int64
 4   Average Temperature         1000 non-null   float64
 5   Day of Week                  1000 non-null   object
 6   Energy Consumption           1000 non-null   float64
dtypes: float64(2), int64(3), object(2)
```

Gambar 1.2: Informasi baris, kolom, dan tipe data variabel dataset *training* yang digunakan

Berdasarkan cuplikan dan informasi yang ditampilkan, dapat diketahui bahwa dataset *training* memiliki 1000 baris dan 7 kolom (variabel). Analisis untuk setiap variabel dapat dilihat pada penjelasan berikut:

- **Variabel independen (fitur):**

- Building Type: merupakan kategori atau tipe bangunan yang tercatat.

- Square Footage: merepresentasikan luas bangunan.
- Number of Occupants: menunjukkan jumlah orang yang menempati atau menggunakan bangunan.
- Appliances Used: menunjukkan jumlah perangkat atau peralatan yang digunakan dalam bangunan.
- Average Temperature: merupakan suhu rata-rata di sekitar atau di dalam bangunan.
- Day of Week: merepresentasikan waktu operasional bangunan berdasarkan hari kerja.
- **Variabel dependen (target):**
 - Energy Consumption: menunjukkan jumlah energi yang digunakan bangunan dalam periode tertentu.

Variabel-variabel tersebut juga dapat dikelompokkan sesuai dengan kategori numerik atau kategorikal sebagai berikut:

- Variabel numerik: Square Footage, Number of Occupants, Appliances Used, Average Temperature, Energy Consumption
- Variabel kategorikal: Building Type, Day of Week

1.2 Check for Missing Values and Duplicates

Sebelum melakukan *preprocessing*, diperlukan pengecekan terhadap nilai yang hilang (*missing values*) dan duplikasi untuk memastikan kualitas dan konsistensi data sehingga tidak terdapat informasi yang tidak lengkap atau duplikat yang dapat mempengaruhi hasil analisis dan kinerja model. Berikut adalah hasil dari pengecekan *missing values* dan duplikasi dari dataset *training*:

	0
Building Type	0
Square Footage	0
Number of Occupants	0
Appliances Used	0
Average Temperature	0
Day of Week	0
Energy Consumption	0

Gambar 1.3: Jumlah *missing values* setiap kolom dataset *training*

```
np.int64(0)
```

Gambar 1.4: Jumlah data duplikat pada dataset *training*

Berdasarkan kedua gambar di atas, tidak ditemukan adanya data dengan nilai yang hilang dan data duplikat sehingga tidak perlu tahap *preprocessing* lebih lanjut untuk menangani *missing values* dan duplikasi.

1.3 Descriptive Statistics

Statistik deskriptif dilakukan pada setiap variabel numerik untuk menganalisis variasi data dan memahami karakteristik dasar seperti nilai rata-rata, sebaran, dan rentang data. Analisis tersebut dapat memberikan gambaran awal mengenai pola distribusi data pada dataset. Berikut adalah statistik deskriptif pada dataset training:

	Square Footage	Number of Occupants	Appliances Used	Average Temperature	Energy Consumption
count	1000.000	1000.000000	1000.000000	1000.000000	1000.000000
mean	25462.388	48.372000	25.606000	22.611390	4166.252570
std	14294.554	29.061972	14.105166	7.139943	933.313064
min	560.000	1.000000	1.000000	10.050000	1683.950000
25%	13169.750	22.000000	13.000000	16.475000	3509.482500
50%	25477.000	47.000000	26.000000	22.815000	4175.730000
75%	37446.250	73.250000	38.000000	28.850000	4863.850000
max	49997.000	99.000000	49.000000	34.990000	6530.600000

Gambar 1.5: Statistik deskriptif pada dataset *training*

Berdasarkan hasil statistik deskriptif, diperoleh informasi sebagai berikut:


- **Square Footage** memiliki rata-rata sekitar 25,462 dengan nilai minimum 560 dan maksimum 49,997. Hal ini menunjukkan variasi luas bangunan yang cukup besar dalam dataset.
- **Number of Occupants** memiliki rata-rata sekitar 48 orang dengan rentang antara 1 hingga 99. Distribusi ini menunjukkan variasi jumlah penghuni yang cukup merata.

- **Appliances Used** memiliki rata-rata sekitar 25 perangkat dengan nilai minimum 1 dan maksimum 49 yang menunjukkan variasi penggunaan perangkat listrik dalam bangunan.
- **Average Temperature** memiliki rata-rata sekitar 22.61°C dengan rentang dari 10.05°C hingga 34.99°C yang menunjukkan suhu lingkungan bangunan yang masih berada dalam rentang realistis.
- **Energy Consumption** sebagai variabel target memiliki rata-rata sekitar 4166 dengan nilai minimum 1683 dan maksimum 6530. Hal ini menunjukkan variasi konsumsi energi yang cukup besar dalam dataset.

Secara keseluruhan, terlihat bahwa nilai mean dan median memiliki jarak yang dekat sehingga sebagian besar variabel memiliki distribusi yang relatif simetris. Namun, terdapat kemungkinan adanya variasi data yang cukup tinggi pada variabel Square Footage dan Energy Consumption yang ditunjukkan oleh nilai standar deviasi yang besar. Selain itu, tidak ditemukan indikasi nilai yang tidak logis (anomali) pada seluruh variabel numerik.

1.4 Data Distribution Analysis

Analisis distribusi data dilakukan untuk memahami pola sebaran data pada setiap variabel numerik sehingga dapat diidentifikasi karakteristik data seperti kecenderungan, variasi, atau potensi penyimpangan yang dapat mempengaruhi pembuatan model. Distribusi data *training* dapat dilihat pada histogram berikut:




Gambar 1.6: Histogram distribusi data numerik pada dataset *training*

Berdasarkan visualisasi histogram distribusi data yang dihasilkan, terlihat bahwa sebagian besar fitur numerik menunjukkan distribusi yang relatif merata. Frekuensi data tersebar dengan cukup seimbang dan tidak menunjukkan kecenderungan (*skew*) yang signifikan. Hal ini mengindikasikan bahwa variasi data pada fitur-fitur tersebut cukup stabil dan tidak didominasi oleh nilai tertentu. Sedangkan pada variabel target *Energy Consumption*, terlihat pola distribusi data yang mendekati distribusi normal. Hal tersebut ditandai dengan distribusi data yang lebih tinggi pada nilai tengah dan penurunan frekuensi secara bertahap ke arah nilai yang lebih rendah maupun nilai yang lebih tinggi.


1.5 Identify Outliers

Identifikasi pecilan (*outlier*) dilakukan untuk menentukan berapa banyak variabel yang memiliki data dengan nilai terlalu tinggi atau terlalu rendah dari mayoritas distribusi data. Keberadaan *outlier* dapat mempengaruhi model melalui bias yang dihasilkan dari nilai yang terlalu tinggi atau terlalu rendah tersebut. Pada statistik deskriptif sebelumnya, variabel *Number of Occupants*, *Appliance Used*, dan *Average Temperature* memiliki rentang nilai yang lumayan kecil sehingga *outlier* dapat

diidentifikasi dengan hanya menggunakan informasi kuartil data dan histogram distribusi saja (hasilnya menunjukkan tidak adanya *outlier*). Oleh karena itu, identifikasi *outlier* yang dilakukan pada bagian ini hanya berfokus pada variabel Square Footage dan Energy Consumption yang memiliki rentang nilai besar. *Outlier* pada dataset *training* diidentifikasi menggunakan *box plot* sebagai berikut:



Gambar 1.7: *Box plot* variabel Square Footage pada dataset *training*



Gambar 1.8: *Box plot* variabel Energy Consumption pada dataset *training*

Berdasarkan visualisasi *box plot* kedua variabel tersebut, tidak ditemukan titik data di luar batas *whisker*. Hal tersebut menandakan bahwa tidak terdapat *outlier* yang

signifikan pada kedua variabel sehingga tidak perlu tahap *preprocessing* lebih lanjut untuk menangani *outlier*.


1.6 Trend Analysis and Visualization

Analisis tren dilakukan dengan menghitung nilai korelasi seluruh fitur numerik dengan variabel target. Hal ini bertujuan untuk mengidentifikasi seberapa besar hubungan antara masing-masing fitur terhadap variabel target sehingga dapat diketahui fitur apa yang memiliki pengaruh paling signifikan dan akan digunakan untuk membuat model. Berikut adalah hasil analisis korelasi untuk seluruh fitur numerik pada dataset *training*:

	Square Footage	Number of Occupants	Appliances Used	Average Temperature	Energy Consumption
Square Footage	1.000000	0.033379	-0.013478	0.027273	0.774873
Number of Occupants	0.033379	1.000000	0.023646	0.014122	0.354485
Appliances Used	-0.013478	0.023646	1.000000	-0.062870	0.312792
Average Temperature	0.027273	0.014122	-0.062870	1.000000	-0.034487
Energy Consumption	0.774873	0.354485	0.312792	-0.034487	1.000000

Gambar 1.9: Analisis korelasi fitur numerik pada dataset *training*

Berdasarkan hasil analisis korelasi, Square Footage merupakan fitur yang paling berpengaruh terhadap Energy Consumption sehingga menjadi kandidat fitur utama yang digunakan dalam pemodelan regresi (khususnya regresi linear sederhana yang hanya menggunakan satu fitur). Sementara itu, fitur lain seperti Number of Occupants dan Appliances Used tetap dipertimbangkan karena memberikan kontribusi tambahan terhadap variasi konsumsi energi. Korelasi Square Footage dengan Energy Consumption dapat dilihat dengan lebih jelas melalui *scatter plot* berikut:



Gambar 1.10: *Scatter plot* Square Footage dengan Energy Consumption pada dataset *training*

Scatter plot pada **Gambar 1.8** menunjukkan kecenderungan peningkatan konsumsi energi seiring bertambahnya luas bangunan. Nilai korelasi sebelumnya (0.77) juga menunjukkan hubungan positif yang cukup kuat antara kedua variabel tersebut. Hal ini menunjukkan bahwa bangunan dengan ukuran yang lebih besar cenderung membutuhkan energi yang lebih tinggi. Pola sebaran data terlihat cukup konsisten sehingga memperkuat indikasi bahwa luas bangunan merupakan salah satu faktor utama yang mempengaruhi konsumsi energi.

1.7 Categorical Variable Analysis

Bagian ini berfokus pada analisis variabel kategorikal pada dataset (khususnya dataset *training*). Berikut adalah kategori yang terdapat pada setiap variabel kategorikal beserta frekuensi untuk setiap kategori tersebut:

	count
Building Type	
Residential	347
Commercial	336
Industrial	317

Gambar 1.11: Frekuensi setiap kategori pada variabel Building Type

count	
Day of Week	
Weekday	507
Weekend	493

Gambar 1.12: Frekuensi setiap kategori pada variabel Day of Week

Berdasarkan distribusi variabel kategorikal, diperoleh informasi sebagai berikut:

- Building Type terdiri dari tiga kategori, yaitu Residential (347 data), Commercial (336 data), dan Industrial (317 data). Distribusi ini relatif seimbang antar kategori sehingga tidak terdapat dominasi yang signifikan dari salah satu tipe bangunan.
- Day of Week terbagi menjadi Weekday (507 data) dan Weekend (493 data). Distribusi ini juga menunjukkan keseimbangan yang baik antara kedua kategori.

Keseimbangan distribusi pada variabel kategorikal dapat mengurangi potensi bias dalam model dan memastikan bahwa setiap kategori dapat direpresentasikan dengan baik saat melatih (*training*) model. Karena kedua variabel bersifat kategorikal, diperlukan proses *encoding* (seperti one-hot encoding) sebelum digunakan dalam model regresi.

1.8 Feature Selection and Justification

Pemilihan fitur dilakukan berdasarkan hasil analisis korelasi, distribusi data, serta relevansi secara domain terhadap variabel target (Energy Consumption). Berikut adalah fitur yang dipilih untuk pembuatan setiap model regresi beserta justifikasinya:

- Pada model **linear regression** biasa, digunakan satu variabel independen yaitu **Square Footage**. Fitur ini dipilih karena memiliki nilai korelasi tertinggi terhadap Energy Consumption (0.77) yang menunjukkan hubungan linear yang kuat sehingga paling berpengaruh dalam prediksi.

- Pada model ***multiple linear regression***, **seluruh fitur** digunakan karena masing-masing variabel memiliki kontribusi secara statistik maupun secara logika terhadap Energy Consumption.
- Pada model **polynomial regression**, fitur utama yaitu **Square Footage** ditransformasikan ke dalam bentuk polinomial untuk menangkap kemungkinan hubungan non-linear antara fitur dan target.

BAB II

TAHAPAN *PREPROCESSING*

2.1 One-hot Encoding

One-hot encoding dilakukan untuk mengubah variabel kategorikal menjadi bentuk numerik agar dapat diproses oleh model *machine learning*. Model seperti regresi linear tidak dapat memproses data dalam bentuk kategori sehingga perlu direpresentasikan dalam bentuk angka. One-hot encoding dilakukan pada variabel Building Type dan Day of Week yang sudah dijelaskan pada bagian *categorical variable analysis* sebelumnya.

	Square Footage	Number of Occupants	Appliances Used	Average Temperature	Energy Consumption	Building Type_Industrial	Building Type_Residential	Day of Week_Weekend
0	7063	76	10	29.84	2713.95	False	True	False
1	44372	66	45	16.72	5744.99	False	False	False
2	19255	37	17	14.30	4101.24	True	False	True
3	13265	14	41	32.82	3009.14	False	True	False
4	13375	26	18	11.92	3279.17	False	False	False

Gambar 2.1: One-hot encoding pada variabel kategorikal

Berdasarkan hasil one-hot encoding, setiap kategori diubah menjadi kolom baru dengan nilai True atau False (1 atau 0) yang merepresentasi nilai dari kategori tersebut. Berikut ini adalah interpretasi kategori yang digunakan:

- **Building Type_Industrial dan Building Type_Residential:** Jika bernilai True, maka data tersebut masuk ke dalam kategorinya masing-masing (Industrial atau Residential). Jika keduanya False, maka data tersebut masuk ke dalam kategori yang tidak ditampilkan (Commercial).
- **Day of Week_Weekend:** Jika bernilai True, maka data tersebut masuk ke kategori Weekend. Jika bernilai False, maka tersebut masuk ke kategori Weekday.

2.2 Separate Independent and Dependent Variable

Tahapan *preprocessing* selanjutnya adalah memisahkan variabel independen (fitur) dan variabel dependen (target). Pemisahan ini dilakukan agar model dapat dilatih menggunakan variabel independen untuk memprediksi variabel dependen

secara terarah. Variabel independen berperan sebagai *input* (X) dalam proses pelatihan model, sedangkan variabel dependen merupakan nilai yang akan diprediksi (y). Hasil dari pemisahan ini kemudian bisa langsung digunakan untuk pembuatan model atau dilanjutkan ke tahap *preprocessing* lanjutan yang diperlukan.

2.3 Feature Scaling

Feature scaling dilakukan untuk menyeimbangkan skala antar fitur agar tidak terdapat perbedaan rentang nilai yang terlalu besar. Hal ini penting dalam pembuatan model *multiple linear regression* karena perbedaan skala dapat mempengaruhi proses pembelajaran model dan interpretasi koefisien. *Scaling* dilakukan setelah fitur dan target sudah dipisahkan dari dataset.

BAB III

EVALUASI MODEL


Dalam mengevaluasi performa model regresi, digunakan beberapa metrik untuk mengukur *error* dan kemampuan model dalam memprediksi target. Setiap model memiliki tiga metrik yang sama yaitu:

- **Mean Absolute Error (MAE)**: mengukur rata-rata selisih absolut antara nilai prediksi dan nilai aktual untuk menunjukkan seberapa besar *error* prediksi secara umum.
- **Mean Squared Error (MSE)**: mengukur rata-rata kuadrat dari selisih antara nilai prediksi dan nilai aktual untuk memberikan penalti lebih besar terhadap *error* yang besar.
- **Koefisien Determinasi (R^2)**: mengukur seberapa baik model mampu menjelaskan variasi pada data. Nilai R^2 yang mendekati 1 menunjukkan bahwa model memiliki kemampuan prediksi yang lebih baik (begitu juga sebaliknya).

Evaluasi setiap model akan dijelaskan pada subbab-subbab berikut:

3.1 Regresi Linear (*Linear Regression*)

Model regresi linear yang dilatih menggunakan fitur Square Footage pada *training* dataset untuk pelatihan dan *testing* dataset sebagai data yang digunakan untuk prediksi memberikan hasil sebagai berikut:



Gambar 3.1: Perbandingan nilai aktual vs nilai prediksi pada model regresi linear

Berdasarkan visualisasi perbandingan antara nilai aktual dan nilai prediksi pada **Gambar 3.1**, terlihat bahwa keduanya membentuk pola yang cukup mirip meskipun masih terlihat perbedaan pada beberapa rentang nilai. Hal ini menunjukkan bahwa model mampu menangkap pola umum pada data tetapi belum cukup akurat untuk merepresentasikan keseluruhan variasi data. Evaluasi model dapat dijelaskan dengan lebih detail menggunakan hasil perhitungan metrik berikut:

Mean absolute error: 480.42
Residual sum of squares (MSE): 334658.43
R2-score: 0.51

Gambar 3.2: Hasil perhitungan MAE, MSE, dan R^2 pada model regresi linear

Hasil perhitungan metrik pada **Gambar 3.2** menunjukkan bahwa:

- Nilai **MAE** sebesar **480.42** menunjukkan bahwa rata-rata selisih antara nilai prediksi dan nilai aktual masih cukup besar.
- Nilai **MSE** sebesar **334,658.43** menunjukkan adanya variasi *error* kuadrat yang cukup besar.
- Nilai **R^2** sebesar **0.51** menunjukkan bahwa model hanya mampu menjelaskan sekitar setengah dari variasi data. Hal ini menunjukkan bahwa penggunaan fitur Square Footage saja masih belum cukup untuk membangun model yang memberikan prediksi dengan lebih akurat.

Secara keseluruhan, model regresi linear sederhana memberikan performa yang cukup sebagai model dasar tetapi masih memiliki keterbatasan dalam memberikan akurasi prediksi yang baik. Hal tersebut terlihat dari nilai *error* yang masih cukup besar dan kemampuan model yang belum optimal dalam menjelaskan variasi data. Model ini belum mampu menangkap hubungan kompleks antar fitur secara keseluruhan.

3.2 Regresi Linear Berganda (*Multiple Linear Regression*)

AAA

3.3 Regresi Polinomial (*Polynomial Linear Regression*)

AAA

3.4 Perbandingan Antar Model

Hasil evaluasi metrik ketiga model sebelumnya dapat dilihat pada tabel perbandingan berikut:

Tabel 3.1: Sub-pertanyaan dari *test case* yang ditentukan

Model Regresi	MAE	MSE	R ²
Regresi Linear	480.42	334,658.43	0.51
Regresi Linear Berganda			
Regresi Polinomial			

[Analisis perbandingan]

BAB IV

ANALISIS PENGARUH FITUR TERHADAP PREDIKSI

4.1 ???

???

BAB V
INTERPRETASI HASIL UNTUK PENGAMBILAN KEPUTUSAN BISNIS